



**TÜBİTAK-2209-A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA
PROJELERİ DESTEĞİ PROGRAMI**

ARAŞTIRMA ÖNERİSİ FORMU

2024 Yılı

1. Dönem Başvurusu

2209/A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEĞİ PROGRAMI
ARAŞTIRMA ÖNERİSİ FORMU

A. GENEL BİLGİLER

Başvuru Sahibinin Adı Soyadı: Hümeysra ÖZTÜRK
Araştırma Önerisinin Başlığı: Derin Öğrenme Tabanlı Quadcopter ile Otonom Araç Takip Sistemi ve Simülasyonu
Danışmanın Adı Soyadı: Dr. Öğr. Üyesi Ulaş YURTSEVER
Araştırmanın Yürütüleceği Kurum/Kuruluş: Sakarya Üniversitesi

ÖZET

Türkçe özetin araştırma önerisinin (a) özgün değeri, (b) yöntemi, (c) yönetimi ve (d) yaygın etkisi hakkında bilgileri kapsamı beklenir. Bu bölümün en son yazılması önerilir.

Projemiz, insansız hava aracı (İHA) kullanarak gerçek zamanlı araç tespiti ve takibi gerçekleştirmeyi amaçlamaktadır. Trafik yoğunluğunu izleme, ulaşım analizleri yapma ve askeri operasyonlarda hedef tespiti gibi birçok alanda araçların doğru şekilde tanımlanması, operasyonların güvenilirliği ve verimliliği açısından kritik bir öneme sahiptir. Yapılan literatür taramaları sonucunda, İHA tabanlı otonom takip sistemlerinin güvenlik, gözetim ve lojistik gibi alanlarda yaygın olarak kullanıldığı, ancak mevcut sistemlerin hedef aracı doğru tanımlama konusunda yetersizlikler barındırdığı tespit edilmiştir. Bu bağlamda, projemiz, gerçek zamanlı benzerlik analizi algoritması kullanarak yalnızca hedef aracı tespit eden ve yanlış pozitif oranını azaltarak yüksek doğrulukla geri bildirim sağlayan bir sistem geliştirmeyi hedeflemektedir. Projenin ilk aşamasında, gerekli donanımlar temin edilerek entegre edilecek ve güvenlik önlemleri alınarak haberleşme menzili ölçümleri, GPS verisi toplama ve motor itki-yön testleri gerçekleştirilecektir. Ayrıca, acil durumlarda güç kesebilmek amacıyla İHA'ya akım kesici bir buton yerleştirilerek tehlikeli durumların önlenmesi planlanmıştır. Donanım entegrasyonunun tamamlanmasının ardından manuel uçuş testleri yapılacak ve Mission Planner yer kontrol istasyonu yazılımı üzerinden araç verileri izlenerek uçuş kayıtları toplanacaktır. Toplanan uçuş verileri, uçuş sonrasında incelenecek ve motor yetersizlikleri, yüksek amper çekimi, ağırlık merkezi kaynaklı dengesizlikler ve komutlara geç yanıt verilmesi gibi olası sorunlara hızlı bir şekilde çözüm bulunacaktır. Projenin ikinci aşamasında, İHA üzerinde çalışacak derin öğrenme modelinin eğitimi için çeşitli mevcut veri setlerinden yararlanılacaktır. Veri setlerinin kıyaslanması sonucunda, yüksek çözünürlükte ve farklı yüksekliklerden çekilmiş araç görüntüleri içermesi nedeniyle "Münih Araç Veri Seti"nin kullanılması uygun bulunmuştur. Ek olarak, test uçuşları sırasında elde edilen görüntüler Roboflow yazılımı kullanılarak etiketlenerek ve mevcut veri setine eklenerek genişletilecektir. Ayrıca, yer kontrol istasyonu aracılığıyla kullanıcının yükleyeceği hedef araç görselleri, tersleme ve yansıma yöntemleriyle çoğaltılarak eğitim veri setine dahil edilecektir. Eğitilen model, Raspberry Pi görev bilgisayarı üzerinde İHA kamerasından gelen canlı görüntüleri işleyerek araç tespiti yapacak, tespit edilen araçlar kullanıcı tarafından yüklenen görsellerle karşılaştırılarak benzerlik oranı hesaplanacaktır. Bu oran belirli bir eşik değerin üzerinde olduğunda, hedef aracın doğru tespit edildiği onaylanacak ve yazılı takip algoritması devreye alınacaktır. Takip algoritması, tespit edilen aracın İHA tarafından sürekli izlenmesini sağlayacaktır. Belirlenen eşik değerin üzerinde benzerlik gösteren bir araç tespit edildiğinde, İHA üzerindeki Raspberry Pi görev bilgisayarı aracılığıyla aracın davranışları analiz edilecek ve bu davranışlara göre İHA, gerçek zamanlı otonom takip işlemi gerçekleştirecektir. Projenin amacı, yalnızca hedef aracın tespitinde doğruluğu artırmakla kalmayıp, aynı zamanda İHA tabanlı nesne tanıma ve takip sistemlerine operasyonel verimlilik kazandırmaktır. Bu proje, derin öğrenme tabanlı yöntemlerin kullanımıyla hem akademik literatüre katkı sağlamayı hem de gerçek dünya uygulamalarında önemli bir çözüm sunmayı hedeflemektedir. Anahtar Kelimeler: Derin Öğrenme, Quadcopter, Otonom Sürüş Algoritması, Araç Takibi

1. ÖZGÜN DEĞER

1.1. Konunun Önemi, Araştırma Önerisinin Özgün Değeri ve Araştırma Sorusu/Hipotezi

Günümüzde insansız hava araçları (İHA) kullanılarak araç tespiti ve takibi üzerine yapılan çalışmalar hızla artmakta olup, bu alanda önemli ilerlemeler kaydedilmiştir. Ancak, mevcut çözümlerde hala bazı zorluklar bulunmaktadır. Özellikle yüksek yanlış pozitif oranları, zorlu hava koşullarında performans kayıpları ve gerçek
--

2209/A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEĞİ PROGRAMI ARAŞTIRMA ÖNERİSİ FORMU

zamanlı çalışmaya uygunluk gibi konular, bu teknolojilerin operasyonel verimliliğini sınırlamaktadır. Araç takibi ve tespiti için kullanılan derin öğrenme tabanlı modeller, yoğun trafik veya karmaşık sahnelerde doğru hedefi ayırt etmekte zorluk çekebilmekte ve bu durum sistemlerin pratik kullanımını engellemektedir.

Bu konuda literatürde yapılmış çalışmalar incelendiğinde Ammour ve arkadaşları (2017), insansız hava aracı görüntülerinden araç algılama ve sayma sorununa çözüm üretmek amacıyla iki aşamalı bir yöntem geliştirmiştir. İlk aşamada, görüntülerin bölütlenmesi için ortalama kaydırma algoritması kullanılmış; ikinci aşamada ise, bölgeden çıkarılan özellikler VGG16 modeli ile elde edilmiş ve bu özellikler, destek vektör makinesi (SVM) sınıflandırıcısı ile birleştirilmiş bir önceden eğitilmiş derin sinir ağı (CNN) kullanılarak sınıflandırılmıştır (Ammour vd., 2017). Çalışma, benzer araştırmalara kıyasla üstün başarı göstermiş olsa da yüksek yanlış pozitif (FP) oranı nedeniyle gerçek zamanlı çalışan uygulamalarda kullanıma uygun olmadığı tespit edilmiştir.

Espinosa ve arkadaşları (2017), kentsel video dizilerinde araç algılama ve sınıflandırma için AlexNet ve Faster R-CNN modellerinin performansını karşılaştırmıştır. AlexNet, kentsel senaryolar için özellik çıkarımı yaparken ve sabit ya da hareketli arka planları ayırt ederken Gaussian Mixture Model (GMM) arka plan çıkarma tekniğini kullanmıştır; ancak, Faster R-CNN modeli F1 skoru açısından daha iyi sonuçlar elde etmiştir (Espinosa vd., 2017).

Abdulghani ve arkadaşları (2022), farklı hava koşullarında hareketli nesne tespiti üzerine yaptıkları araştırmada, gündüz, gece, yağmurlu, sisli ve karlı hava koşullarında YOLOv4, YOLOv3 ve Faster R-CNN algoritmalarını kullanarak insan, araç, otobüs ve motosiklet gibi nesneleri tespit etmeye çalışmıştır. Çalışma bulguları, YOLOv4'ün yoğun yağmur ve karanlık dışındaki tüm koşullarda başarılı olduğunu; YOLOv3'ün ise gece veya karlı koşullarda yeterli performansı sağlayamadığını göstermektedir. Faster R-CNN ise gece, sisli ve yağmurlu hava koşullarında başarısız performans sergilemiştir (Abdulghani & Menekşe Dalveren, 2022).

Türk Bilim Araştırma Vakfı Dergisi'nde yayımlanan bir çalışmada, insansız hava araçları ile farklı yüksekliklerden alınan alan fotoğrafları kullanılarak araç tespiti ve sayımı gerçekleştirilmiş, bu görüntüler etiketlenerek hazır veri setlerine eklenmiş ve Faster R-CNN ile YOLO algoritmaları kullanılarak test edilmiştir (Dıkbayır & Bülbül, 2020). Test sonuçları, YOLO algoritmasının %95,61 başarı oranı ile Faster R-CNN'nin %91,76 oranını aştığını ortaya koymuştur. Ayrıca, video testlerinde Faster R-CNN'nin ortalama 20,89 FPS hızına karşın, YOLO algoritması ortalama 57,16 FPS ile daha yüksek bir hız sergilemiş ve araştırmanın geri kalanında kullanılmak üzere tercih edilmiştir.

Literatürde yapılan çalışmalar, İHA tabanlı araç tespiti ve takibi konusunda önemli ilerlemeler sağlamış olsa da yüksek yanlış pozitif oranları, zorlu hava koşullarındaki performans düşüklükleri ve gerçek zamanlı çalışmaya uygunluk gibi alanlarda **hala çözüm bekleyen zorluklar mevcuttur**. Tek aşamalı ve iki aşamalı derin öğrenme modelleri kullanılarak yapılan önceki çalışmalar, belirli başarılar elde etse de karmaşık ortamlarda güvenilirlik ve doğruluk konusunda yetersiz kalmıştır. Özellikle, yanlış pozitif oranlarının yüksek olması ve yoğun trafik veya karmaşık sahnelerde doğru hedefin takip edilememesi gibi sorunlar, mevcut sistemlerin operasyonel verimliliğini sınırlamaktadır.

Bu projede ise, literatürde gözlemlenen bu eksiklikleri gidermek amacıyla, gerçek zamanlı benzerlik analizi algoritması kullanılarak yeni bir otonom takip sistemi geliştirilmesi hedeflenmektedir. Projemiz, yanlış pozitifleri minimize ederek yalnızca hedef aracın doğru bir şekilde tespit edilmesi ve takip edilmesini sağlamayı amaçlamaktadır. Bu doğrultuda, mevcut veri setleri İHA'lar ile elde edilen yeni görüntülerle genişletilecek ve bu görüntüler etiketlenerek model eğitiminde kullanılacaktır. Ayrıca, belirlenen eşik değerin üzerinde benzerlik oranına sahip araçların tespiti durumunda, quadcopter'in otonom takip algoritması devreye alınacak ve böylece sistemin kullanım alanları genişletilecektir. Bu **yenilikçi yaklaşım**, hem araç tespitinde yüksek doğruluk sağlayarak operasyonel verimliliği artırmayı hem de İHA tabanlı nesne tanıma ve takip sistemlerinde önemli metodolojik katkılar sunmayı hedeflemektedir.

Bu araştırmanın temel sorusu, derin öğrenme (deep learning) algoritmalarını kullanarak araç tespit ve takibinin mevcut yöntemlere kıyasla daha güvenilir olup olmadığını incelemektir. Araştırma kapsamında, hedef aracın yanlış tanımlanması, yanlış hedeflerin peşine düşülmesi veya karmaşık ortamlarda hedefin kaybolması gibi sorunların üstesinden gelinmesi amaçlanmaktadır. Bu doğrultuda **hipotezimiz**, derin öğrenme tabanlı bir takip algoritmasının, hedef aracın tespitinde ve sürekli takibinde daha yüksek doğruluk sağlayarak operasyonların güvenilirliğini ve verimliliğini artıracaktır.

2209/A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEĞİ PROGRAMI ARAŞTIRMA ÖNERİSİ FORMU

1.2. Amaç ve Hedefler

Bu projenin temel amacı, drone kullanarak yalnızca hedef aracın doğru şekilde tespit edilmesini ve takibini sağlamakla kalmayıp, İHA tabanlı nesne tanıma ve takip sistemlerine operasyonel verimlilik kazandırmaktır. Derin öğrenme algoritmaları kullanılarak araç tespit ve takibinin mevcut yöntemlere kıyasla daha güvenilir olup olmadığını değerlendirmeyi amaçlayan bu projede, Faster R-CNN ve YOLOv7 algoritmaları bir arada kullanılarak yüksek doğrulukta araç tespiti hedeflenmektedir. Aynı zamanda, benzerlik oranı analizi ile yanlış pozitiflerin en aza indirilmesi ve yalnızca doğru hedefe odaklanılması planlanmaktadır.

Projenin bir diğer önceliği, karmaşık ortamlarda hedef aracın kaybolmadan uzun süreli olarak takip edilmesini mümkün kılacak bir otonom takip algoritması geliştirmektir. Bu sayede, yanlış hedeflerin takibi önlenerek, hedef aracın tanımlama doğruluğu artırılacaktır. Bu doğrultuda, geniş ve zenginleştirilmiş bir veri seti ile modelin eğitim kalitesinin artırılması ve TensorFlow ile Keras gibi güçlü derin öğrenme kütüphaneleri kullanılarak performans optimizasyonunun sağlanması hedeflenmektedir.

Hedefler:

1. **Yüksek doğrulukta araç tespiti** sağlamak amacıyla Faster R-CNN ve YOLOv7 algoritmalarını bir arada kullanarak sistem performansını optimize etmek.
2. Yanlış pozitif oranını en aza indirerek **yalnızca hedef araca odaklanacak** bir benzerlik analizi algoritması geliştirmek.
3. **Karmaşık ortamlarda** hedef aracın kaybolmadan takip edilmesini mümkün kılacak bir otonom takip algoritması oluşturmak.
4. Geniş ve etiketlenmiş bir veri seti kullanarak **modelin eğitim kalitesini artırmak** ve böylece daha yüksek doğruluk oranlarına ulaşmak.
5. TensorFlow ve Keras kütüphanelerini kullanarak, **model performansını optimize etmek** ve gerçek zamanlı çalışabilen bir sistem geliştirmek.
6. Geliştirilen sistemin **farklı hava koşullarında ve zorlu ortamlarda** test edilerek, operasyonel güvenilirliğini artırmak.

2. YÖNTEM

Derin Öğrenme

Derin öğrenme, yapay zeka (YZ) alanında, sinir ağlarının çok katmanlı yapılarını kullanarak verilerden otomatik olarak öğrenme ve karar verme süreçlerini modelleyen bir tekniktir. Bu yöntem, insan beyninin öğrenme mekanizmalarına benzer şekilde çalışır ve veri içerisindeki karmaşık ilişkileri modelleyerek sonuçlar üretir. Derin öğrenme, genellikle "yapay sinir ağları" adı verilen algoritmalarla gerçekleştirilir. (Krizhevsky vd., 2017) Bu ağlar, çok sayıda katmandan oluşur ve her bir katman, girdilere belirli bir dönüşüm uygulayarak daha soyut özellikler çıkarır. Giriş katmanı ham verileri alırken, ara katmanlar bu verileri analiz eder ve son katman sonuçları sınıflandırarak çıktı üretir. Derin öğrenme, özellikle büyük veri kümeleri ile çalışırken yüksek doğruluk elde edebilmesiyle öne çıkar. Bu süreç, geleneksel makine öğrenmesi tekniklerine göre daha fazla hesaplama gücü gerektirir, ancak doğru yapılandırıldığında çok güçlü sonuçlar verebilir. Derin öğrenme uygulamaları, görüntü tanıma, sesli komutlar, otonom araçlar, dil çevirisi ve daha birçok alanda başarılı bir şekilde kullanılmaktadır. (Farabet vd., 2013; Tompson vd., 2014)

Bu projemizde hızları ve yüksek doğruluk oranlarıyla öne çıkan, her biri Derin Öğrenme modeli olan YOLOv7 ve Faster R-CNN algoritmaları; bu modellerin eğitimlerinde görev alacak olan ve yine Derin Öğrenme tabanlı birer kütüphane olan Keras ve TensorFlow kütüphanelerini kullanılacaktır.

YOLOv7 Algoritması

YOLOv7 (You Only Look Once version 7), gerçek zamanlı nesne algılama alanında en son gelişmeleri temsil eden, hızlı ve verimli bir derin öğrenme algoritmasıdır. YOLOv7, önceki sürümlerine kıyasla daha yüksek doğruluk ve işlem verimliliği sunar. Algoritmanın temel prensibi, bir görüntü üzerinde tek bir geçişte nesnelerin konumunu ve sınıfını tespit etmektir, bu da onu hızlı ve düşük gecikme süreli uygulamalar için ideal kılar. Özellikle güvenlik sistemleri, otonom araçlar ve video akışı analizleri gibi gerçek zamanlı işlemlerin kritik olduğu projelerde yaygın olarak kullanılır. Projemizde, YOLOv7 algoritması, aracın ilk tespiti ve genel takibi aşamalarında kullanılacak ve bu modelin hızlı çalışması sayesinde projede akıcı bir işlem süreci sağlanacaktır ([Gelar Guntara, 2023; Wang vd., 2022](#))

YOLOv7 algoritmasının farklı çözünürlüklerdeki performansları, istatistiksel ölçütlerle analiz edilmiştir. YOLOv7–320px için F1 skoru %96,3, YOLOv7–512px için %96,4 ve YOLOv7–640px için %96,6 olarak hesaplanmıştır. Ayrıca, belirli koşullar altında yapılan testlerde, modelin mAP (Mean Average Precision) değeri %80,4 olarak tespit edilmiş ve orijinal modelden %5,5 daha yüksek olduğu görülmüştür. Bu iyileştirme ile model boyutu %15,81 oranında küçültülerek, donanım gereksinimleri azaltılmıştır ([Zhang vd., 2023; Zhao vd., 2023](#)). Bunun yanında, modelin ortalama mutlak hata (MAE) değeri 2.737 olarak hesaplanmış ve orijinal modele kıyasla %5,69 daha düşük olduğu kaydedilmiştir. Geliştirilen bu deneysel modelin, daha güçlü ve dayanıklı performansı ile donanım uygulamaları ve saha verim tahmini gibi alanlarda yeni perspektifler sunduğu vurgulanmıştır ([Olorunshola vd., 2023](#)).

YOLOv7 algoritması, hızlı ve gerçek zamanlı görüntü işleme kabiliyeti sayesinde bu projede aracın ilk tespit aşamasında kullanılacaktır. Tablo 1’de de görüldüğü üzere bu model, Faster R-CNN modeline göre yüksek hızlı ve gerçek zamanlı çalışmaya daha uygun fakat nispeten daha düşük doğrulukta çalışmaktadır. Bu yüzden bu model projemiz içerisinde hız ve gerçek zamanlı performans gerektiren yerlerde kullanılacaktır. Modelin eğitiminde kullanılmak üzere yapılan veri seti araştırması sonucunda Tablo 2 üzerinde belirtilen veri setlerine ulaşılmış olup, yüksek çözünürlükte ve farklı yüksekliklerden çekilmiş araç görüntüleri içermesi nedeniyle “Münih Araç Veri Seti” kullanılması uygun bulunmuştur. Bu veri seti ile eğitilen model sonucunda kamera açısına giren araçların tespit edilmesi hedeflenmektedir. Araç tespiti olması durumunda, kullanıcının takip etmemizi istediği araç ile tespit edilen aracın görüntüsü arasında benzerlik analizi yapacağımız ikinci aşama başlayacaktır.

Faster R-CNN Algoritması

Faster Region-Based Convolutional Neural Network (R-CNN), yüksek doğruluk ve detaylı nesne algılama gerektiren uygulamalar için geliştirilmiş, iki aşamalı bir derin öğrenme algoritmasıdır. İlk aşama olan Region Proposal Network (RPN), görüntüdeki olası nesne bölgelerini hızlı bir şekilde önerir. İkinci aşamada ise bu bölgeler, konvolüsyonel bir sinir ağı tarafından analiz edilerek sınıflandırılır ve sonuçları üretilir. Bu çift aşamalı yapı, hatalı algılamaların azaltılmasını ve karmaşık sahnelerdeki nesnelerin yüksek doğrulukla tespit edilmesini sağlar. Faster R-CNN, detaylı nesne tanımlamalarının kritik olduğu projelerde tercih edilir ([Maity vd., 2021; Xu vd., 2022](#)). **Projemizde, aracın ayrıntılı özelliklerinin (renk, model, marka vb.) analiz edilmesi ve doğru nesnenin tanımlanması aşamasında Faster R-CNN algoritması kullanılacaktır.**

Faster R-CNN, bir nesne algılama çerçevesi olarak, çeşitli performans analizlerine tabi tutulmuş ve bu analizler farklı metriklerle değerlendirilmiştir. Örneğin, bir çalışmada, COCO veri kümesindeki performans mAP (mean Average Precision) metriği üzerinden analiz edilmiştir. Faster R-CNN, bu analizde %34,90 gibi bir mAP skoru elde etmiştir. Bu değer, diğer ileri seviye algoritmalarla karşılaştırıldığında nispeten düşük kalmakta olup, DyHead (%60,60) ve NAS-FPN (%50,70) gibi daha yeni algoritmaların gerisinde kalmıştır. Faster R-CNN’nin F1 skoru ve MAE gibi istatistikler açısından sonuçları da farklı çalışmalarda incelenmiş, genellikle orijinal modelden düşük performans sergilediği belirtilmiştir ([Fan vd., 2016](#)).

İkinci aşama, aracın belirli ayırt edici özelliklerinin detaylı bir şekilde tespit edilmesini gerektirdiğinden, Tablo 1 üzerinde görüldüğü gibi doğruluk oranı çok daha yüksek ve hassas algılama yapabilmesi ile öne çıkan Faster R-CNN modeli tercih edilecektir. Modelin eğitimi öncesinde, kullanıcıdan alınan tespit edilmesi istenen araca ait görüntüler üzerinde çeşitli filtreleme ve düzenlemeler yapılarak farklı ışık koşullarını temsil eden yeni görseller oluşturulacak ve bu şekilde genişletilmiş bir veri seti elde edilecektir. Daha sonra, bu yeni veri seti kullanılarak Faster R-CNN modeli eğitilecek ve benzerlik analizi için kullanılacaktır. Bu aşamada, aracın renk, marka ve model gibi detaylı özellikleri taranacak ve istenen özelliklere sahip araç tespit edildiğinde üçüncü ve son aşamamız olan otonom takip aşaması başlayacaktır.

2209/A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEĞİ PROGRAMI
ARAŞTIRMA ÖNERİSİ FORMU

Tablo 1. Faster R-CNN ve YOLOv7 Karşılaştırması

Özellik	Faster R-CNN	YOLOv7
Algoritma Tipi	İki aşamalı (region proposal ve sınıflandırma)	Tek aşamalı (doğrudan sınıflandırma ve algılama)
Doğruluk	Yüksek doğruluk, hassas nesne algılama	Yüksek doğruluk, ancak bazı durumlarda Faster R-CNN daha hassas olabilir
Hız	Daha yavaş (gerçek zamanlı uygulamalara uygun değil)	Çok hızlı, gerçek zamanlı uygulamalara uygun
Region Proposal Network (RPN)	Var, bu sayede hassas algılama yapılır	Yok, tek bir aşamada sınıflandırma yapılır
Kullanım Alanları	Güvenlik, yüz tanıma, detaylı görüntü analizi	Otonom araçlar, robotik, güvenlik kameraları gibi gerçek zamanlı uygulamalar
Yüksek Yoğunluklu Nesne Ortamları	Daha başarılı	Daha hızlı ama bazen yoğun ortamlarda doğruluk düşebilir
Öğrenme Eğrisi	Daha karmaşık	Görece daha basit
Kapsamlı Veri İhtiyacı	Orta-yüksek (hassas sonuçlar için fazladan veri gerektirir)	Orta, ancak iyi optimize edilmiştir

Tablo 2. Sık Tercih Edilen Araç Veri Setleri

Veri Seti	Kaynak	Farklı Aç	Çözünürlük	Format	Araç Sayısı
OIRDS	Uydu	Mevcut	Düşük	Sınırlayıcı kutu	180
VEDAI	Uydu	Mevcut	Düşük	Sınırlayıcı kutu	295
COWC	İHA	Mevcut	Düşük	Araç merkezli seçim	32.716
PUCPR	Kamera	Mevcut	Yüksek	Sınırlayıcı kutu	192.216
CARPK	Drone	Mevcut değil	Yüksek	Sınırlayıcı kutu	89.777
Münih	Uydu	Mevcut	Yüksek	Sınırlayıcı kutu	-

Keras Kütüphanesi

Keras, derin öğrenme projelerinde basitlik ve kullanıcı dostu bir yapı sunan açık kaynaklı bir kütüphanedir. Yüksek seviyeli bir API sağlayarak makine öğrenmesi modellerinin hızlı ve kolay bir şekilde geliştirilmesine olanak tanır. Keras, genellikle TensorFlow'un bir parçası olarak bilinse de Theano ve CNTK gibi diğer arka uçlar üzerinde de çalışabilir. Bu kütüphane, anlaşılır bir yapı ve modüler bir sistem sunarak model geliştirme süreçlerini hızlandırır. Keras'ın önemli avantajlarından biri, Sequential ve Functional API gibi esnek model tasarım seçenekleri sunmasıdır. (Ketkar, 2017)

Keras kütüphanesinin öne çıkan özelliklerinden biri kullanım kolaylığıdır. API yapısı hem yeni başlayanlar hem de uzmanlar için hızlı prototipleme ve detaylı model tasarımına olanak tanır. Ayrıca taşınabilirlik konusunda da

2209/A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEĞİ PROGRAMI
ARAŞTIRMA ÖNERİSİ FORMU

avantaj sağlar; Keras, farklı platformlarda çalıştırılabilecek modeller geliştirmenizi mümkün kılar. Örneğin, bir model masaüstünde eğitilip mobil cihazda çalıştırılabilir. Keras ayrıca zengin bir topluluk desteğine sahiptir. Geniş bir kullanıcı topluluğuna ve kapsamlı belgelere sahip olması, öğrenme sürecini ve sorun çözme kolaylaştırır (Manaswi & Manaswi, 2018; Moolayil, Moolayil, & John, 2019).

Tablo 3 üzerinde belirtilen özelliklere dayanarak Keras kütüphanesi ile model eğitmek TensorFlow kütüphanesine göre daha hızlı ve kolaydır. Bu yüzden başlangıç aşamasında YOLOv7 modeli eğitimi için Keras kütüphanesinin kullanımı tercih edilecektir.

Tablo 3. Keras ve TensorFlow Kütüphaneleri'nin Karşılaştırması

Özellik	Keras	TensorFlow
Geliştirilme Amacı	Derin öğrenme modellerini hızlı ve kolay bir şekilde geliştirmek	Makine öğrenmesi ve derin öğrenme araştırmaları ve üretim uygulamaları için kapsamlı bir framework
Dil Desteği	Python, R	Python, C++, Java, Go, Swift
Modülerlik Ve Kullanım	Yüksek modülerlik, kullanıcı dostu arayüz	Daha karmaşık ama esneklik sunar
Arkaplan Motoru	TensorFlow (varsayılan olarak)	Kendi altyapısı
Model Tipleri	Sekansiyel, Fonksiyonel ve Model Alt Sınıfları	Her tür sinir ağı tipi
Veri Girişi	NumPy dizileri, TF Dataset'ler	NumPy dizileri, TFRecord, TF Dataset'ler
Eğitim Hızları	Orta (yüksek seviyede soyutlama)	Daha yüksek hız (düşük seviyeli API'ler kullanıldığında)
Dağıtım Ve Üretim	TensorFlow üzerinden çalışır	TensorFlow Lite, TensorFlow.js, TensorFlow Serving
GPU Desteği	TensorFlow sayesinde mevcut	CUDA ve ROCm gibi GPU hızlandırma kütüphaneleri ile doğrudan destek
Model Hacmi Ve Verim	Küçük ve orta ölçekli modeller için daha verimli	Büyük ölçekli modeller için optimize edilmiş
Genişletilebilirlik	Daha kısıtlı, belirli sınırlarda genişletilebilir	Çok genişletilebilir; düşük seviyeli operasyonlar kolayca eklenebilir
Uygulama Alanları	Prototip geliştirme ve araştırmalar	Araştırma, üretim sistemleri ve özelleştirilebilir projeler

TensorFlow Kütüphanesi

TensorFlow, makine öğrenmesi ve derin öğrenme uygulamaları için endüstri standardı bir platformdur. Google Brain ekibi tarafından geliştirilen bu kütüphane, büyük ve karmaşık veri setleri üzerinde çalışabilecek esneklikte olup, CPU ve GPU tabanlı işlemleri destekler. TensorFlow'un geniş araç yelpazesi, onu kapsamlı projeler için uygun hale getirir; TensorFlow Lite mobil ve gömülü cihazlar için, TensorFlow.js ise web tabanlı uygulamalar için geliştirilmiştir. Ayrıca, TensorFlow Extended (TFX), uçtan uca makine öğrenmesi boru hatlarının oluşturulmasına yönelik çözümler sunar (Pang vd., 2020; Singh & Manure, 2020).

TensorFlow, Keras API'sini entegre bir şekilde kullanarak model oluşturma ve eğitim süreçlerini basitleştirir. TensorFlow'un en önemli avantajlarından biri, graph execution ile büyük ölçekli projelerin verimli çalışmasını sağlamasıdır. Otomatik diferansiyasyon özelliği, derin öğrenme modellerinin optimizasyonunda önemli olan gradyan hesaplamalarının TensorFlow tarafından otomatik olarak yapılmasını sağlar. Model taşınabilirliği açısından TensorFlow, eğitilen modellerin bulut, masaüstü, mobil ve web ortamlarında sorunsuz çalışmasını destekler (Dillon vd., 2017).

TensorFlow'un paralel işlem yetenekleri sayesinde büyük veri setlerinde model eğitimi hızlı bir şekilde yapılabilir. Distributed training özelliği ile birden fazla işlemci ve GPU üzerinde aynı anda çalışılabilir. TensorFlow'un güçlü API'leri ve esnekliği, özelleştirilmiş model tasarımı ve hiperparametre optimizasyonu için idealdir (Goldsborough, 2016).


TensorFlow kütüphanesinin eğitim gücü, Tablo 3'de görüldüğü üzere Keras kütüphanesine göre daha fazladır. Bu nedenle araçların detaylı özelliklerini yüksek doğruluk oranı ile tespit edecek olan Faster R-CNN modeli TensorFlow kütüphanesi kullanılarak eğitilecek ve doğru aracın takip edilmesi sağlanacaktır.

Otonom Uçuş ve Otopilot Yönetimi

ArduPilot, otonom araç kontrolü için kullanılan açık kaynaklı, modüler ve kapsamlı bir otopilot yazılım platformudur. Multikopterler (ArduCopter), sabit kanatlı uçaklar (ArduPlane), kara araçları (ArduRover), su altı ve su üstü araçları (ArduSub ve ArduBoat) gibi birçok farklı araç tipini destekleyen alt modülleri bulunur. Yazılım, C++ tabanlı olarak geliştirilmiş olup, gerçek zamanlı işletim sistemi (RTOS) desteği sayesinde yüksek stabilite ve güvenilirlik sağlar. PID kontrol algoritmaları aracılığıyla araçların hassas stabilizasyonu sağlanırken, GPS, IMU, barometre ve manyetometre gibi çok çeşitli sensörlerden veri toplayarak aracın durumunu ve konumunu sürekli olarak izler ve kontrol eder ([Hadi vd., 2014](#)).

ArduPilot, MAVLink protokolü aracılığıyla yer kontrol istasyonları ile iletişim kurarak telemetri verileri ve komutları aktarır; bu özellik, araçların otonom görevlerini yerine getirirken anlık kontrol ve izleme imkânı sunar. Yazılım, açık kaynaklı yapısı ve geniş topluluk desteği sayesinde sürekli güncellenmekte ve özelleştirme açısından büyük esneklik sağlamaktadır. Kullanıcılar, ihtiyaçlarına uygun özel kontrol algoritmalarını veya davranış modellerini entegre edebilir ([Mendoza-Mendoza vd., 2020](#)).

Bu projede aracın kontrolü için **Pixhawk 2.4.8** uçuş kontrol kartı kullanılacaktır. Pixhawk 2.4.8, ArduPilot yazılımı ile tam uyumlu, açık kaynaklı ve güçlü bir donanım platformu sunarak otonom araçların hassas kontrolünü ve veri işleme yeteneklerini artırır. Kontrolcü, GPS, IMU, barometre ve diğer çevresel sensörleri destekleyerek, aracın anlık stabilizasyonu ve yönlendirilmesinde yüksek performans sağlar ([Meier vd., 2011](#)). Şekil 1'de gösterilen quadcopter nihai sistem mimarisi, uçuş kontrol kartı, telemetri, batarya vb. projemizde kullanacak olduğumuz ekipmanların bağlantı şemasını göstermektedir. Aynı envanterimizde bulunan ve kullanacak olduğumuz ekipmanlar Şekil 2'de belirtilmiştir. Bu malzemeler projemizin temel bileşenlerini oluşturmakta olup, eksik olan diğer komponentler ilerleyen süreçte bütçe tedariği sonrası temin edilecektir.



Şekil 1. Quadcopter Nihai Sistem Mimarisi



Şekil 2. Envanterde Bulunan Ekipmanlar

Mission Planner (IP1, IP2, IP6)

Mission Planner, insansız hava araçları (İHA) ve otonom sistemler için planlama, kontrol ve veri analizi sağlayan popüler bir yer kontrol yazılımıdır. ArduPilot ile uyumlu olarak çalışan bu yazılım, kullanıcı dostu arayüzü ve geniş özellik seti ile hem hobi kullanıcıları hem de profesyoneller tarafından tercih edilir. Mission Planner, kullanıcıların uçuş rotalarını harita üzerinde kolayca planlamalarına, gerçek zamanlı telemetri verilerini izlemelerine ve donanım kalibrasyonu yapmalarına olanak tanır. Uygulama, farklı uçuş modları arasında geçiş yapmayı destekler ve otomatik iniş-kalkış gibi gelişmiş özellikler sunar (Oyelami vd., 2023).

Mission Planner, Windows üzerinde çalışır ve MAVLink protokolünü kullanarak güvenilir veri iletişimi sağlar. ArduPilot tabanlı multikopterler, sabit kanatlı uçaklar, rover ve su altı araçları gibi farklı araçlarla uyumludur. Telemetri verilerinin kaydedilip analiz edilebilmesi, simülasyon desteği ve firmware güncellemeleri gibi özellikler, İHA performansının optimize edilmesine yardımcı olur. Yazılım, uzun menzilli uçuşlar için harici anten takip sistemleri ve veri bağlantı modülleriyle de uyumludur. Mission Planner uygulamasının varsayılan arayüzü Şekil 3'te verildiği gibidir. Açık kaynak kodlu olması sayesinde bu arayüz üzerinde çeşitli değişiklikler yapılarak projemize uygun hale getirilecektir. Arayüz üzerine, kullanıcının takibini istediği aracın görsel ve çeşitli özelliklerini girebileceği bir alan hazırlanarak eklenecektir.

2209/A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEĞİ PROGRAMI
ARAŞTIRMA ÖNERİSİ FORMU



Şekil 3. Mission Planner Yer Kontrol İstasyonu


İletişim Protokolü

MAVLink protokolü: Otonom araçlarda veri aktarımı ve telemetri sağlama konusunda endüstri standardı olarak kabul edilir. Özellikle düşük gecikmeli veri iletiminde yaklaşık %98 başarı oranı sağladığı rapor edilmiştir. MAVLink, iletişim hatalarının minimuma indirilmesi ve güvenilir veri aktarımı için tercih edilmektedir ([Atoev vd., 2017](#))

MAVProxy: ArduPilot ile MAVLink protokolünü kullanarak daha stabil bir bağlantı sağlaması amacıyla kullanılmıştır. Bu protokol, bağlantı sürekliliğini %90'ın üzerinde sağlamakta ve özellikle veri kaybının azaltılması açısından önem arz etmektedir ([Allouch vd., 2019](#)).

Simülasyon Ortamı

Gazebo, gerçek dünya fizik simülasyonunu yüksek doğrulukla sağladığı ve birçok araştırmacı tarafından tercih edildiği için seçilmiştir. Gazebo'nun Quadrotor simülasyonunda %90 üzerinde doğruluk oranı sağladığı raporlanmıştır ve ArduPilot ile entegre edilebilmesi nedeniyle tercih edilmiştir. Şekil 4'te kullanım arayüzü verilmiş olan simülasyon ortamının, çeşitli çalışmalarda kullanılması sonucunda gerçek dünya testleri ile %85 uyumlu sonuçlar verdiği rapor edilmiştir ([Koenig & Howard, 2004](#)).



Şekil 4. Gazebo Simülasyon Ortamı

Otonom Sürüş Performansının Değerlendirilmesi ve Ölçüm Metrikleri

Görev Tamamlama Süresi: Görev tamamlama süresi aracın kalkışı tamamlama anından başlar ve araç takibi bittiği anda son bulur. Simülasyon testlerinde, görev tamamlama süresi analiz edilerek otonom sürüş algoritmasının etkinliği değerlendirilecektir. Ortalama görev tamamlama süresi, otonom sürüş kabiliyeti doğruluğu üzerinde belirleyici bir faktördür. Öncelikle aracın teknik verileri (batarya kapasitesi, ağırlık, motor gücü vb.) gibi veriler değerlendirilerek, teorik olarak aracın ulaşabileceği süre hesaplanır. Bu hesaplamalar yapıldıktan sonra simülasyon üzerinde görev başlatılarak görev süresi hesaplanır. Aracın teorik uçuş süresi, görev süresinden en az %30 daha fazla ise otonom sürüş algoritması ve görüntü işleme modellerinin hızları testi geçmiş sayılır.

F1 Skoru: F1 Skoru, sınıflandırma görevlerinde modelin doğruluğunu ölçen önemli bir metriktir. Hassaslık (precision) ve duyarlılık (recall) arasındaki dengeyi sağlar ve şu formülle ifade edilir:

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

Precision, modelin pozitif olarak sınıflandırdığı nesneler arasından gerçekten doğru olanların oranını gösterir. Diğer bir deyişle, modelin doğru tahmin oranıdır. Recall ise, gerçekte pozitif olan nesneler arasından modelin doğru tespit edebildiği oranı temsil eder ve modelin tüm doğru nesneleri yakalama yeteneğini ölçer. F1 Skoru, özellikle dengesiz veri setlerinde hassaslık ve duyarlılığı tek bir ölçüt altında toplayarak denge sağlar (Huang vd., 2015)

Ortalama Mutlak Hata (MAE - Mean Absolute Error): MAE, bir modelin tahmin ettiği değerlerle gerçek değerler arasındaki hata oranını ölçen bir metriktir. Formülü şu şekildedir:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

Burada y_i , gerçek değeri; $\hat{y}_i$, modelin tahmin ettiği değeri ve n veri sayısını ifade eder. MAE, tahminlerdeki sapmaların mutlak değerlerini alarak ortalama bir hata değeri sunar. Daha düşük bir MAE değeri, modelin tahminlerinin gerçek değerlere daha yakın olduğunu gösterir. Özellikle sürekli veri tahminlerinde kullanışlıdır ve hata payını sade bir şekilde gösterir (Chai & Draxler, 2014).

2209/A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEĞİ PROGRAMI
ARAŞTIRMA ÖNERİSİ FORMU

Ortalama Doğruluk (AP - Average Precision): AP, özellikle nesne algılama ve sınıflandırma gibi derin öğrenme uygulamalarında yaygın olarak kullanılan bir doğruluk metriğidir. Modelin farklı eşik değerlerinde gösterdiği performansa göre ortalama bir doğruluk skoru sağlar ve genellikle %0 ile %100 arasında ifade edilir. AP'nin hesaplanma adımları şöyledir:

1. Modelin tahminlerinin doğruluğu, belirli bir eşik değere göre (örneğin %50 veya %75) Intersection over Union (IoU) metriği kullanılarak belirlenir.
2. Precision ve Recall eğrisi oluşturulur ve her eşik değerinde modelin doğruluk performansı hesaplanır.
3. Bu eğrinin altında kalan alan (AUC - Area Under Curve), AP değeri olarak adlandırılır.

AP, nesne algılama projelerinde modelin performansını analiz etmek için önemlidir. Yüksek bir AP değeri, modelin farklı nesne türlerini doğru bir şekilde tanıyabildiğini gösterir. Genellikle, farklı eşik değerlerinde hesaplanan ortalama bir AP değeri olan mean Average Precision (mAP), modelin genel doğruluk performansını geniş bir bakış açısıyla değerlendirmeye olanak tanır (Yılmaz & Aslam, 2008).

Bu üç ölçüt, bir modelin doğruluk ve hata oranını kapsamlı bir şekilde değerlendirmeye yardımcı olur. F1 Skoru, dengeli bir sınıflandırma performansı sunarken; MAE, modelin hata oranını; AP ise nesne tanıma görevlerinde farklı eşik değerlerindeki doğruluk performansını gösterir.

Detayları verilen bu yöntemlerin iş paketleri ile olan ilişkileri aşağıda verilmiştir.

IP1 - Malzeme Tedariği Sonrası Donanım Entegrasyonu ve Uyumluluk Testleri

Bu aşamada, quadcopter için gerekli donanımlar temin edilerek entegrasyon yapılacaktır. Donanım entegrasyonunun ardından, **ArduPilot** yazılımı ve **Mission Planner** yer kontrol istasyonu kullanılarak donanımların uyumluluk testleri yapılacaktır. **Pixhawk uçuş kontrol kartı** kullanılarak GPS, IMU, barometre gibi sensörlerin kalibrasyonu yapılacak ve sistemin stabil çalıştığından emin olunacaktır. Ayrıca, **MAVLink** protokolü aracılığıyla telemetri verileri alınarak haberleşme testleri gerçekleştirilecektir.

IP2 - Manuel Uçuş Testleri ile PID Kontrollerinin Ayarlanarak Stabil Uçuş Sağlanması

İkinci aşamada, hava aracının stabil uçuş yapabilmesi için **PID kontrol ayarları** optimize edilecektir. Bu süreçte, **Autotune modu** kullanılarak PID değerleri otomatik olarak optimize edilecektir. **Mission Planner** üzerinden uçuş verileri analiz edilecek, manuel uçuşlar sırasında toplanan veriler aracılığıyla aracın dengesizlikleri giderilecektir. Ayrıca, **Gazebo simülasyon ortamı** kullanılarak uçuş testleri simüle edilecek ve gerçek dünya testlerinden önce sanal ortamda iyileştirmeler yapılacaktır.

IP3 - Veri Seti Genişletme ve Etiketleme

Üçüncü aşamada, quadcopter uçuşları sırasında toplanan görüntüler kullanılarak veri seti genişletilecektir. Toplanan bu görüntüler **Roboflow yazılımı** kullanılarak etiketlenecek ve hazır veri setleri (**Münih Araç Veri Seti**) ile birleştirilerek zenginleştirilecektir. Etiketleme işlemi sırasında **bilgisayar destekli etiketleme araçları** kullanılacaktır. Ayrıca, elde edilen görüntüler üzerinde çeşitli **veri artırma (data augmentation)** teknikleri uygulanarak modelin daha verimli öğrenmesi sağlanacaktır.

IP4 - Derin Öğrenme Modelleri ile Model Eğitimi ve Benzerlik Analizi

Bu aşamada, etiketlenmiş veri seti kullanılarak **YOLOv7** ve **Faster R-CNN** modelleri ile araç tespiti gerçekleştirilmek üzere derin öğrenme modelleri eğitilecektir. **TensorFlow** ve **Keras** kütüphaneleri kullanılarak model eğitimi yapılacaktır. Eğitim sonrası, araç tespiti yapıldıktan sonra kullanıcı tarafından yüklenen araç görselleriyle **benzerlik analizi** yapılacaktır. Bu aşamada, **cosine similarity**, **structural similarity index (SSIM)** metrikleri kullanılarak araçların eşleşme oranları hesaplanacaktır. Benzerlik oranı belirli bir eşik değeri aştığında, araç doğru şekilde tespit edilmiş kabul edilecektir.

IP5 - Otonom Takip Algoritmasının Geliştirilmesi

Beşinci aşamada, eğitilen derin öğrenme modelleri ve benzerlik analizi kullanılarak geliştirilmiş bir **otonom takip algoritması** oluşturulacaktır. **Gazebo simülasyon ortamı** kullanılarak algoritmanın karmaşık ortamlardaki performansı test edilecek ve **ArduPilot** yazılımı kullanılarak gerçek zamanlı otonom takip senaryoları

2209/A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEĞİ PROGRAMI
ARAŞTIRMA ÖNERİSİ FORMU

uygulanacaktır. Quadcopter, tespit edilen araçları **gerçek zamanlı olarak takip edebilmek** için **PID kontrol sistemleri** ve **derin öğrenme modelleri** ile entegre şekilde çalışacaktır.

IP6 - Sistem Entegrasyonu ve Test Süreci

Son aşamada, tüm sistem bileşenleri entegre edilerek nihai testler yapılacaktır. **Mission Planner** yazılımı kullanılarak tüm sistemin entegrasyonu doğrulanacak ve uçuş testleri gerçekleştirilerek sistem stabilitesi sağlanacaktır. **YOLOv7** ve **Faster R-CNN** modellerinin entegrasyonu sonrası sistemin farklı hava koşulları ve ortamlarda nasıl performans gösterdiği değerlendirilecektir. Ayrıca, **Gazebo simülasyonu** ile yapılan testlerden elde edilen veriler, gerçek dünya test sonuçlarıyla karşılaştırılarak sistem performansı optimize edilecektir.

2209/A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEĞİ PROGRAMI ARAŞTIRMA ÖNERİSİ FORMU

3 PROJE YÖNETİMİ

3.1 İş- Zaman Çizelgesi

İŞ-ZAMAN ÇİZELGESİ (*)

İP No	İş Paketlerinin Adı ve Hedefleri	Kim(ler) Tarafından Gerçekleştirileceği	Zaman Aralığı (.-.. Ay)	Başarı Ölçütü ve Projenin Başarısına Katkısı
1	Malzeme tedariki sonrası donanım entegrasyonu ve uyumluluk testleri Hedefler: Tüm donanım bileşenlerinin sorunsuz bir şekilde entegre edilmesi ve sistemin düzgün çalıştığına test edilmesi. Bu aşama, diğer iş paketlerinin temelini oluşturur.	Bartu Alp Eren Hümeysra Öztürk	0-2	Donanım bileşenlerinin %100 entegrasyonu ve sistem testlerinin en az %90 başarı ile tamamlanması. Proje başarısına katkısı: %10
2	Manuel uçuş testleri ile hava aracının PID kontrollerinin ayarlanarak stabil uçuş sağlanması. Hedefler: Hava aracının güvenli ve stabil uçuş yapabilmesi için PID kontrollerinin optimize edilmesi.	Bartu Alp Eren Hümeysra Öztürk	2-4	Stabil uçuş testlerinde %90 başarı oranı elde edilmesi ve ortalama uçuş süresinin en az 10 dakika olması. Proje başarısına katkısı: %10
3	Hazır veri setlerine ek olarak manuel uçuşlarda elde edilen görüntüler üzerinde etiketleme yapılması ve veri seti hazırlanması Hedefler: Etiketlenmiş verilerle zenginleştirilmiş bir veri seti oluşturmak ve model eğitimi için temel oluşturmak.	Hilal Bozkaya	4-6	En az 1000 etiketli görüntü ile veri setinin genişletilmesi. Proje başarısına katkısı: %10
4	Hazırlanan veri setleri ile derin öğrenme algoritmaları kullanılarak model eğitimi ve benzerlik analizi hesaplaması Hedefler: Faster R-CNN ve YOLOv7 kullanılarak yüksek doğrulukla araç tespiti sağlamak ve yanlış pozitif oranını azaltmak.	Bartu Alp Eren Hümeysra Öztürk Hilal Bozkaya	6-8	Modelin en az %80 doğruluk oranına ulaşması ve benzerlik analizi ile doğruluğun artırılması, yanlış pozitiflerin azaltılması. Proje başarısına katkısı: %25
5	Otonom takip algoritması geliştirilmesi. Hedefler: Hedef aracı karmaşık ortamlarda bağımsız ve doğru bir şekilde takip edebilecek bir algoritma geliştirmek.	Bartu Alp Eren Hümeysra Öztürk	8-10	Otonom takip doğruluğunun en az %80'in üzerinde olması. Proje başarısına katkısı: %25
6	Sistem entegrasyonu ve test süreci Hedefler: Tüm bileşenlerin entegrasyonu tamamlanarak sistemin stabil çalışmasının test edilmesi.	Bartu Alp Eren Hümeysra Öztürk Hilal Bozkaya	10-12	Sistem entegrasyonunun tamamlanmış olması ve tüm sistem testlerinin tamamlanması. Proje başarısına katkısı: %20

(*) Çizelgedeki satırlar ve sütunlar gerektiği kadar genişletilebilir ve çoğaltılabilir.

2209/A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEĞİ PROGRAMI
ARAŞTIRMA ÖNERİSİ FORMU

3.2 Risk Yönetimi

RİSK YÖNETİMİ TABLOSU*

İP No	En Önemli Riskler	Risk Yönetimi (B Planı)
1	Malzeme tedarikçisinde gecikmeler veya donanımın uyumsuz çıkması	Alternatif tedarikçilerle önceden iletişime geçilecek ve yedek donanım seçenekleri araştırılacak. Uyumsuz donanım durumunda, uyumluluk sağlamak için yazılım güncellemeleri kullanılacak.
2	PID kontrol ayarlarının yetersiz kalması ve stabil uçuşun sağlanamaması	Hava aracı autotune moduna alınarak PID değerleri tekrar alınacak
3	Manuel uçuşlardan yeterli veri elde edilememesi	Yetersiz veri durumunda, çevrimiçi veri setlerinden ek görüntüler temin edilerek veri seti zenginleştirilecek.
4	Model eğitimi sırasında düşük doğruluk oranları veya benzerlik analizinde yanlış pozitiflerin yüksek olması	Yanlış pozitifleri azaltmak amacıyla veri seti çeşitlendirilecek ve daha fazla örnek eklenerek algoritma yeniden eğitilecek.
5	Otonom takip algoritmasında hedefin kaybolması veya algoritmanın stabil çalışmaması	Hedefin kaybolması durumunda araç tespit algoritmasına geri dönülerek tekrar eşik değeri geçen bir eşleşme aranacaktır.
6	Tüm sistem entegrasyonu sırasında uyumsuzluk sorunları veya işlevsel hatalar	Uçuş sırasında alınan log kayıtları incelenerek sorunlar tespit edilip giderilecek, yeterli sayıda test uçuşu yapılacaktır.

3.3. Araştırma Olanakları

ARAŞTIRMA OLANAKLARI TABLOSU (*)

Kuruluştaki Bulunan Altyapı/Ekipman Türü, Modeli (Laboratuvar, Araç, Makine-Teçhizat, vb.)	Projede Kullanım Amacı
Kamera Sistemleri	Görüntü işleme, veri toplama ve analiz için yüksek çözünürlüklü fotoğraf çekimi
Bilgisayar	Veri analizi, simülasyon çalışmaları ve yazılım geliştirme
Telemetri Sistemi	Hava aracı ve yer kontrol istasyonu arasındaki haberleşme
Lipo Batarya	Hava aracı ve diğer elektronik cihazlar için enerji sağlama
GPS	Hava aracı konum takibi ve otonom navigasyon
Motor Sürücü – ESC (80-100A)	Motor hızının kontrol ve stabil uçuş sağlama
Pixhawk Uçuş Kontrol Kartı	Otonom sürüş algoritmalarının uygulanması ve stabil uçuş kontrolü
Raspberry Pi 4	Gerçek zamanlı veri işleme ve otonom sürüş algoritması kontrolü
Kumanda – Kumanda Alıcısı	Acil durumlarda manuel müdahale sağlama

2209/A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEĞİ PROGRAMI
ARAŞTIRMA ÖNERİSİ FORMU

4. YAYGIN ETKİ

ARAŞTIRMA ÖNERİSİNDEN BEKLENEN YAYGIN ETKİ TABLOSU

Yaygın Etki Türleri	Önerilen Araştırmadan Beklenen Çıktı, Sonuç ve Etkiler
Bilimsel/Akademik (Makale, Bildiri, Kitap Bölümü, Kitap)	Proje sonuçları üniversite bünyesinde düzenlenen seminer ve etkinliklerde sunulacak, akademik çevre ve öğrencilerle paylaşılacaktır. Proje tamamlandıktan sonra sonuçlar uluslararası bir kongrede bildiri olarak sunulması hedeflenmektedir.
Ekonomik/Ticari/Sosyal (Ürün, Prototip, Patent, Faydalı Model, Üretim İzni, Çeşit Tescilli, Spin-off/Start- up Şirket, Görsel/İşitsel Arşiv, Envanter/Veri Tabanı/Belgeleme Üretimi, Telif Konu Olan Eser, Medyada Yer Alma, Fuar, Proje Pazarı, Çalıştay, Eğitim vb. Bilimsel Etkinlik, Proje Sonuçlarını Kullanacak Kurum/Kuruluş, vb. diğer yaygın etkiler)	Proje sonunda geliştirilen prototip, üniversite etkinliklerinde sergilenecek ve seminerlerde sunulacaktır.
Araştırmacı Yetiştirilmesi ve Yeni Proje(ler) Oluşturma (Yüksek Lisans/Doktora Tezi, Ulusal/Uluslararası Yeni Proje)	Proje, öğrenciler arasında otonom sistemler ve yapay zekâ uygulamaları hakkında bilgi ve deneyim kazanmalarına katkıda bulunacak. Elde edilen kazanımlar, ileride yapılacak yeni projelerde değerlendirilecektir.

5. BÜTÇE TALEP ÇİZELGESİ

Bütçe Türü	Talep Edilen Bütçe Miktarı (TL)	Talep Gerekçesi
Sarf Malzeme	9000 TL	4 Adet Fırçasız DC Motor ve Pervane 4 Adet Motor Sürücü – ESC (40A) - Quadcopter Frame Kiti
Makina/Teçhizat (Demirbaş)	0 TL	
Hizmet Alımı	0 TL	
Ulaşım	0 TL	
TOPLAM	9000 TL	

6. BELİRTMEK İSTEDİĞİNİZ DİĞER KONULAR

Sadece araştırma önerisinin değerlendirilmesine katkı sağlayabilecek bilgi/veri (grafik, tablo, vb.) eklenebilir.

--

7. EKLER

EK-1: KAYNAKLAR

1. Abdulghani, A. M. A., & Dalveren, G. G. M. (2022). Moving object detection in video under different weather conditions using YOLO and Faster R-CNN algorithms. *European Journal of Science and Technology*, 23 January. <https://doi.org/10.31590/ejosat.1013049>
2. Allouch, A., Cheikhrouhou, O., Koubâa, A., Khalgui, M., & Abbes, T. (2019, June). MAVSec: Securing the MAVLink protocol for ardupilot/PX4 unmanned aerial systems. In 2019 15th International Wireless Communications & Mobile Computing Conference (IWCMC) (pp. 621-628). IEEE.
3. Ammour, N., Alhichri, H., Bazi, Y., Benjdira, B., Alajlan, N., & Zuair, M. (2017). Deep learning approach for car detection in UAV imagery. *Remote Sensing*. <https://doi.org/10.3390/rs9040312>
4. Atoev, S., Kwon, K. R., Lee, S. H., & Moon, K. S. (2017, November). Data analysis of the MAVLink communication protocol. In 2017 International Conference on Information Science and Communications Technologies (ICISCT) (pp. 1-3). IEEE.
5. Chai, T., & Draxler, R. R. (2014). Root mean square error (RMSE) or mean absolute error (MAE)?—Arguments against avoiding RMSE in the literature. *Geoscientific model development*, 7(3), 1247-1250.
6. Dıkbayır, H. S., & Bülbül, H. İ. (2020). DERİN ÖĞRENME YÖNTEMLERİ KULLANARAK GERÇEK ZAMANLI ARAÇ TESPİTİ. *TÜBAV Bilim Dergisi*, 13(3), 1-14.)
7. Dillon, J. V., Langmore, I., Tran, D., Brevdo, E., Vasudevan, S., Moore, D., ... & Saurous, R. A. (2017). Tensorflow distributions. arXiv preprint arXiv:1711.10604.
8. Espinosa, J.E., Velastin, S.A. y Branch, J.W. (2017). Vehicle Detection Using Alex Net and Faster R-CNN Deep Learning Models: A Comparative Study. In *Advances in Visual Informatics*. Lecture Notes in Computer Science, 10645, pp. 3-15. DOI: https://doi.org/10.1007/978-3-319-70010-6_1
9. Fan, Q., Brown, L., & Smith, J. (2016, June). A closer look at Faster R-CNN for vehicle detection. In 2016 IEEE intelligent vehicles symposium (IV) (pp. 124-129). IEEE.
10. Farabet, C., Couprie, C., Najman, L. & LeCun, Y. (2013). Learning hierarchical features for scene labeling. *IEEE Trans. Pattern Anal. Mach. Intell.*, 35, 1915–1929.
11. Goldsborough, P. (2016). A tour of tensorflow. arXiv preprint arXiv:1610.01178.
12. Guntara, R. G. (2023). Pemanfaatan Google Colab Untuk Aplikasi Pendeteksian Masker Wajah Menggunakan Algoritma Deep Learning YOLOv7. *Jurnal Teknologi Dan Sistem Informasi Bisnis*, 5(1), 55-60. <https://doi.org/10.47233/jteksis.v5i1.750>
13. Hadi, G. S., Varianto, R., Trilaksono, B. R., & Budiyo, A. (2014). Autonomous UAV system development for payload dropping mission. *Journal of Instrumentation, Automation and Systems*, 1(2), 72-77.
14. Huang, H., Xu, H., Wang, X., & Silamu, W. (2015). Maximum F1-score discriminative training criterion for automatic mispronunciation detection. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 23(4), 787-797.
15. Ketkar, N., & Ketkar, N. (2017). Introduction to keras. *Deep learning with python: a hands-on introduction*, 97-111.
16. Koenig, N., & Howard, A. (2004, September). Design and use paradigms for gazebo, an open-source multi-robot simulator. In 2004 IEEE/RSJ international conference on intelligent robots and systems (IROS)(IEEE Cat. No. 04CH37566) (Vol. 3, pp. 2149-2154). IEEE.
17. Krizhevsky, A., Sutskever, I. & Hinton, G. ImageNet classification with deep convolutional neural networks. In *Proc. Advances in Neural Information Processing Systems* 25 1090–1098 (2012).
18. Maity, M., Banerjee, S., & Chaudhuri, S. S. (2021, April). Faster r-cnn and yolo based vehicle detection: A survey. In *2021 5th international conference on computing methodologies and communication (ICCMC)* (pp. 1442-1447). IEEE.
19. Manaswi, N. K., & Manaswi, N. K. (2018). Understanding and working with Keras. *Deep learning with applications using Python: Chatbots and face, object, and speech recognition with TensorFlow and Keras*, 31-43.
20. Meier, L., Tanskanen, P., Fraundorfer, F., & Pollefeys, M. (2011, May). Pixhawk: A system for autonomous flight using onboard computer vision. In 2011 IEEE international conference on robotics and automation (pp. 2992-2997). IEEE.
21. Mendoza-Mendoza, J. A., Gonzalez-Villela, V. J., Sepulveda-Cervantes, G., Mendez-Martinez, M., & Sossa-Azuela, H. (2020). Advanced robotic vehicles programming: an ArduPilot and Pixhawk approach. Apress.
22. Moolayil, J., Moolayil, J., & John, S. (2019). Learn Keras for deep neural networks (pp. 33-35). Berkeley, CA, USA: Apress.
23. Olorunshola, O. E., Irhebhude, M. E., & Ewiewpaefe, A. E. (2023). A comparative study of YOLOv5 and YOLOv7 object detection algorithms. *Journal of Computing and Social Informatics*, 2(1), 1-12.
24. Oyelami, A. T., Bamgbose, O. M., & Akintunlaji, O. A. (2023). Mission-Planner Mapped Autonomous Robotic Lawn Mower. *Journal Européen des Systèmes Automatisés*, 56(2), 253-258.
25. Pang, B., Nijkamp, E., & Wu, Y. N. (2020). Deep learning with tensorflow: A review. *Journal of*

- Educational and Behavioral Statistics*, 45(2), 227-248.
26. Singh, P., Manure, A., Singh, P., & Manure, A. (2020). Introduction to tensorflow 2.0. *Learn TensorFlow 2.0: Implement Machine Learning and Deep Learning Models with Python*, 1-24.
 27. Tompson, J., Jain, A., LeCun, Y. & Bregler, C. (2014). Joint training of a convolutional network and a graphical model for human pose estimation. In *Proc. Advances in Neural Information Processing Systems* 27 1799–1807.
 28. Wang, Y., Wang, H., & Xin, Z. (2022). Efficient detection model of steel strip surface defects based on YOLO-V7. *IEEE Access*, 10, 133936-133944.
 29. Xu, X., Zhao, M., Shi, P., Ren, R., He, X., Wei, X., & Yang, H. (2022). Crack detection and comparison study based on faster R-CNN and mask R-CNN. *Sensors*, 22(3), 1215.
 30. Yilmaz, E., & Aslam, J. A. (2008). Estimating average precision when judgments are incomplete. *Knowledge and Information Systems*, 16(2), 173-211.
 31. Zhang, Y., Sun, Y., Wang, Z., & Jiang, Y. (2023). YOLOv7-RAR for urban vehicle detection. *Sensors*, 23(4), 1801.
 32. Zhao, H., Zhang, H., & Zhao, Y. (2023). Yolov7-sea: Object detection of maritime uav images based on improved yolov7. In *Proceedings of the IEEE/CVF winter conference on applications of computer vision* (pp. 233-238).